



Facultad de Ingenierías
Análisis Multivariado
Maestría en Inteligencia Artificial y Ciencia de Datos
Prof. Cristian E Garcia.

Desafío 3

Condiciones:

- Subir la tarea en formato pdf en la plataforma UAO-Virtual.
- Es necesario incluir el código de R, Python o Julia. Mostrar los resultados a partir de tablas, gráficos o indicadores que les permita dar respuesta a los planteamientos.
- Deben interpretar los resultados obtenidos en cada situación de acuerdo al contexto.

Situación 1

A partir de los registros históricos de viajes correspondientes a los servicios **Yellow Taxi**, **Green Taxi**, **For-Hire Vehicles (FHV)** y **High Volume FHV** (formato **PARQUET** [link](#)) de la ciudad de Nueva York, integre y analice de manera conjunta estos cuatro conjuntos de datos con el propósito de **identificar y estimar estructuras latentes** que expliquen los patrones multivariados asociados a tres variables de interés operacional:

1. La probabilidad de que un viaje incluya propina,
2. La cantidad de pasajeros transportados por viaje, y
3. El monto de propina efectivamente recibido.

Para ello debe construir un **modelo multivariado robusto** sustentado en técnicas de extracción de factores y de componentes independientes, que incorpore —de manera articulada y comparativa— los métodos de **Análisis de Componentes Principales (PCA)**, **PCA Disperso (Sparse PCA)**, **Kernel PCA**, **Análisis de Componentes Independientes (ICA)** y **Independent Vector Analysis (IVA)**. Adicionalmente, el deberá complementar dicho proceso mediante **análisis factorial exploratorio**, **modelos multivariados con múltiples respuestas** y **técnicas de agrupamiento (clustering)**, con el propósito de evaluar la estabilidad, interpretabilidad y relevancia operativa de los componentes latentes obtenidos.

Mediante una evaluación comparativa y sistemática de métodos de reducción de dimensionalidad y aprendizaje no supervisado, **¿cuál es el modelo de estructura factorial más robusto, interpretable y válido para caracterizar la dinámica subyacente en los datos de viajes?**

La robustez y validez del modelo final se evaluarán en función de su capacidad para:

1. **Interpretabilidad y Parsimonia:** Identificar constructos latentes significativos y parsimoniosos (p. ej., "Eficiencia del Viaje", "Costo-Distancia", "Demanda del Cliente").
2. **Coherencia de Segmentación:** Producir segmentaciones de viajes (clústeres) que sean analíticamente coherentes y operativamente útiles.
3. **Validez Predictiva:** Demostrar una influencia estadísticamente significativa y teóricamente relevante sobre las variables de resultado clave: la probabilidad de recibir una propina, la cantidad de pasajeros por viaje y el monto de la propina recibida.

Situación 2

El conjunto de datos [Single-Family Fixed-Rate Loan Performance Data](#) ofrece una visión longitudinal y granular del desempeño de préstamos hipotecarios en Estados Unidos. La alta dimensionalidad y la interdependencia temporal de estas variables (originación, desempeño mensual, características del prestatario) presentan un desafío analítico. La identificación de patrones subyacentes, más allá de los indicadores de riesgo tradicionales, es fundamental para una gestión de cartera proactiva, una tarificación (pricing) precisa y el diseño de políticas de originación robustas.

Objetivo General

Desarrollar un estudio multivariado avanzado para identificar, modelar y caracterizar las estructuras latentes que explican los patrones de comportamiento crediticio observados en el portafolio hipotecario, utilizando dichas estructuras para generar una segmentación de riesgo interpretable.

Fases del Estudio (Metodología)

El estudiante deberá ejecutar secuencialmente las siguientes fases analíticas:

1. **Construcción del Panel Analítico:** Integrar y preparar las diversas tablas del conjunto de datos (originación, desempeño mensual, atributos del prestatario e inmueble) para construir un panel analítico longitudinal y coherente. Este panel debe ser apto para el estudio conjunto de variables de riesgo, capacidad de pago y desempeño histórico.
2. **Extracción de Componentes Latentes (IVA):** Aplicar el método de **Análisis de Vectores Independientes (IVA)**. El objetivo es extraer componentes *multivista* que capturen la información compartida entre distintos grupos de variables (p. ej., dominios del préstamo, del prestatario y del comportamiento mensual). Se busca que estas fuentes latentes expliquen la heterogeneidad multivariada del portafolio de manera compacta.
3. **Evaluación e Interpretación de Componentes:** Evaluar y contrastar los componentes extraídos mediante IVA con los indicadores tradicionales de riesgo crediticio. El análisis debe centrarse en la interpretabilidad, estabilidad y relevancia de los componentes para caracterizar patrones de morosidad, prepago, incumplimiento y amortización.
4. **Segmentación Basada en Características Latentes:** Utilizar las proyecciones (scores) de los componentes independientes obtenidos como base para un proceso de **Análisis de Conglomerados**. Se deberán explorar técnicas como k-means, Gaussian Mixture Models (GMM) o clustering jerárquico para segmentar los préstamos en grupos homogéneos.

5. Caracterización de Perfiles de Riesgo: Interpretar y validar los conglomerados resultantes. La caracterización debe realizarse en términos de perfiles de riesgo, rasgos financieros del prestatario y propiedades estructurales del préstamo.

Resultados Esperados y Evaluación

Se espera que el análisis finalice con una discusión crítica sobre la utilidad potencial de las segmentaciones encontradas para tareas de gestión de riesgo, monitoreo de cartera o políticas de originación.

La evaluación se centrará en la demostración de una integración sólida de técnicas avanzadas (IVA y Clustering) y en la capacidad del estudiante para interpretar patrones complejos dentro de un portafolio hipotecario real.

Situación 3

Utilizando el conjunto de datos SUSAS ([link](#)), que proporciona grabaciones de voz bajo múltiples condiciones de estrés (simulado y real), se plantea un desafío en dos fases para evaluar la capacidad de ICA e IVA para aislar y caracterizar la "firma del estrés" como un componente independiente de la señal de voz.

Fase 1: Aplicación de ICA

En este escenario, simularemos una grabación de dos canales en una sala de interrogatorios donde hablan dos individuos: un "interrogador" (calmado) y un "sujeto" (bajo estrés).

1. **Preparación:** Seleccione dos archivos de audio del dataset SUSAS:
 - **Fuente 1 (S1):** Una grabación "Neutra" (sin estrés).
 - **Fuente 2 (S2):** Una grabación "Estresada" (p.ej., *High Task Load* o *Lombard Effect*).
2. **Simulación:** Cree dos "grabaciones de micrófono" (M1 y M2) mediante una mezcla lineal artificial (p.ej., $M1 = 0.7 \cdot S1 + 0.3 \cdot S2$; $M2 = 0.4 \cdot S1 + 0.6 \cdot S2$).
3. **Pregunta (ICA):** Aplicando el **Análisis de Componentes Independientes (ICA)**, ¿en qué medida es posible separar y recuperar las señales de las fuentes originales (S1 y S2) a partir de las mezclas observadas (M1 y M2)? Evalúe la calidad de la separación cualitativa (auditiva) y cuantitativamente (si es posible, usando métricas como SIR - Signal-to-Interference Ratio).

Fase 2: Aislamiento de la Firma de Estrés (Aplicación de IVA)

En este escenario, en lugar de mezclar hablantes, usaremos la estructura *multivista* de SUSAS. Consideraremos cada condición de estrés como un "conjunto de datos" o "vista" diferente.

1. **Preparación:** Seleccione múltiples grabaciones del *mismo hablante* diciendo la *misma palabra*, pero bajo diferentes condiciones (vistas). Por ejemplo:
 - **Vista 1 (D1):** Grabación "Neutra".
 - **Vista 2 (D2):** Grabación "Estresada - Tarea Baja".
 - **Vista 3 (D3):** Grabación "Estresada - Tarea Alta".

- Nota: Para aplicar IVA, es crucial que las fuentes (componentes) estén correlacionadas o sean dependientes a través de los datasets.
- 2. **Pregunta (IVA):** Aplicando el **Análisis de Vectores Independientes (IVA)**, ¿es posible descomponer las señales de voz en vectores fuente que separen la "identidad vocal" del hablante (el componente común en todas las vistas) de la "firma del estrés" (el componente que modula la voz de manera consistente a través de las vistas D2 y D3)?
- 3. **Análisis:** Interprete los vectores fuente resultantes. ¿Se aisló un componente que represente clara y unívocamente la modulación fisiológica inducida por el estrés? ¿Cómo se compara este enfoque con un ICA simple aplicado a cada dataset por separado?

Situación 4

Como Científico de datos se le ha solicitado realizar un Análisis Multitemporal de Dinámicas de Cobertura Forestal usando Datos de Landsat Science para la Detección de Deforestación y Recuperación.

El conjunto de datos de [Landsat Science](#), mantenido por la USGS, proporciona el archivo de imágenes satelitales multiespectrales de observación de la Tierra de resolución media más largo y continuo, abarcando desde la década de 1970 hasta la actualidad. Estos datos son una fuente autorizada para el análisis de series temporales, permitiendo la derivación de índices de vegetación (NDVI, EVI, NBR) para cuantificar procesos de cambio del uso del suelo, deforestación, degradación y recuperación de ecosistemas boscosos a escala global. A partir de un subconjunto de datos multitemporales del archivo de **Landsat Science** para un área de interés específica, desarrollar un estudio multivariado para identificar, aislar y caracterizar las estructuras latentes que explican los patrones de cambio en la cobertura forestal. Se le solicita considerar y ejecutar los siguientes puntos:

1. Construcción de un Cubo Multivariado Espacio-Temporal:

- Integrar una serie temporal de imágenes Landsat (p. ej., Landsat 5, 7, 8, 9) para cubrir un período de análisis significativo (mínimo 10-15 años).
- Extraer las bandas espectrales relevantes (p. ej., Rojo, Infrarrojo Cercano - NIR, Infrarrojo de Onda Corta - SWIR).
- Calcular índices de vegetación clave asociados a la salud forestal (NDVI, EVI, NBR, NDMI) para cada imagen en la serie temporal.
- Generar un dataset multivariado (cubo de datos) por píxel, donde cada píxel es una observación y las bandas/índices de cada año son las variables.

2. Identificación de Componentes Latentes (ACP/ICA):

- Aplicar **Análisis de Componentes Principales (ACP)** o **Sparse PCA** al cubo de datos para capturar la variabilidad temporal dominante e identificar los principales modos de cambio.
- Aplicar **Análisis de Componentes Independientes (ICA)** para intentar separar fuentes independientes de cambio (p. ej., perturbaciones abruptas como incendios, degradación progresiva, o recuperación post-evento).
- Interpretar las componentes resultantes y vincularlas con eventos ecológicos plausibles (p. ej., cambio de uso de suelo, sequías).

3. Aplicación Obligatoria de IVA (Independent Vector Analysis):

- Tratar diferentes fuentes de variación como "vistas" para un modelo **IVA**.
- Las *vistas* pueden ser: distintos índices de vegetación (p. ej., Vista 1=Serie NDVI, Vista 2=Serie NBR), o datos de diferentes temporadas (p. ej., Vista 1=Estación Seca, Vista 2=Estación Húmeda) a lo largo de los años.
- El objetivo es identificar componentes independientes *multivista* que revelen patrones persistentes de deforestación, regeneración o degradación que sean capturados simultáneamente por diferentes índices o temporadas.

4. Detección de Zonas de Cambio (Clustering):

- Sobre los factores o componentes extraídos (de ACP, ICA o IVA), aplicar técnicas de **Análisis de Conglomerados (ACO)** (p. ej., k-means, GMM) para segmentar los píxeles.
- El objetivo es identificar regiones espaciales que muestren trayectorias de cambio homogéneas: pérdida significativa de cobertura, estabilidad ecológica, recuperación forestal activa, o patrones transicionales.
- El estudiante deberá generar **mapas temáticos** claros que muestren la distribución espacial de estos clústeres.

5. Evaluación Cuantitativa del Cambio:

- Para cada clúster identificado, calcular métricas clave: tasas de deforestación/recuperación anual, magnitud del cambio en los índices y líneas de tendencia temporal.
- El análisis debe incluir visualización multivariada y mapas que resuman el cambio.

6. Interpretación Ecológica y Conclusiones:

- Interpretar los factores latentes y los clústeres en términos de procesos ecológicos y antropogénicos reales (expansión agrícola, áreas protegidas, etc.).
- Discutir las limitaciones (p. ej., cobertura de nubes en datos Landsat) y las aplicaciones de los hallazgos en monitoreo, conservación y políticas ambientales.